


ASTRO JOURNAL 2025

UNA INTRODUCCION A LA INFERENCIA BAYESIANA USANDO ALGORITMOS MCMC

Holman D. Quintero
Salazar



STARLIGHT Project


CIGALE

Code Investigating GALaxy Emission

SteParSyn

prospector


UTILIDAD DE LOS MCMC




QUE SIGNIFICA MCMC?

Las Cadenas de Markov Monte Carlo (Markov Chain Monte Carlo) son una familia de algoritmos empleados en ciencia para muestrear funciones de probabilidad.

MONTE CARLO



CADENAS DE MARKOV



INFERENCIA DE PARÁMETROS CON MCMC

En cosmología y astrofísica muchos de los problemas consisten en tener un conjunto de datos del cual se quiere inferir algo:

- Inferir valores de parámetros libres →

Cual es el valor de los parámetros fundamentales que describen el modelo LCDM?

Cual es la masa de un agujero negro en un merger?

- Probar una hipótesis →

La SED o el espectro que obtengo despues de la síntesis espectral realmente describe el espectro o la fotometría original?

- Seleccionar un modelo →

El merger de dos agujeros negros es el evento más probable que ocurrió?

Es la relatividad general la teoría correcta y final, o teoría de gravedad modificada funcionan mejor?



INFERENCIA BAYESIANA VERSUS FRECUENTISTA




FRECUENTISTA

- Interpreta la probabilidad como frecuencia de ocurrencia a largo plazo. Los parámetros son desconocidos pero fijos. La incertidumbre proviene solo de la variabilidad de los datos.
- Se define una función objetivo χ^2 y se optimiza
- No da una distribución completa de incertidumbre.
- No incorpora conocimiento previo
- Mala para evaluar degeneraciones, bimodalidades, o distribuciones no gaussianas.



BAYESIANA

- Interpreta la probabilidad como grado de creencia. Los parámetros son variables aleatorias y se modelan con una distribución de probabilidad.
- Se define una verosimilitud y se eligen priors explícitos
- Requiere más poder computacional
- Depende de las elecciones de los priors
- Requiere criterios cuidadosos de convergencia y análisis de "burn-in".

Característica	Frecuentista (χ^2)	Bayesiano (MCMC)
Parámetros	Fijos, desconocidos	Variables aleatorias
Resultado	Mejor ajuste + error aproximado	Distribución completa de probabilidad
Correlaciones/Degeneraciones	Limitado a casos simples	Totalmente visibles y cuantificables
Intervalos	De confianza (no probabilísticos)	De credibilidad (probabilísticos)
Distribuciones no gaussianas	Problemas para describirlas	Captura colas, asimetrías, etc.
Modelos no lineales / complejos	Aproximación puede fallar	Excelente desempeño
Uso de información previa	No permitido	Totalmente integrado (priors)
Interpretación física	Más abstracta	Más directa (probabilidad real)



$$\log L = \alpha \log \sigma + \beta$$




TEOREMA DE BAYES PARA INFERENCIA DE PARAMETROS

Dados los datos que observamos, y un modelo, cual es la probabilidad que un conjunto de parámetros describa nuestros datos

$$P(A | B) = \frac{P(B | A) * P(A)}{P(B)}$$

$$P(\vec{\theta} | \text{Datos, Modelo}) = \frac{\mathcal{L}(\text{Datos} | \vec{\theta}, \text{Modelo}) \pi(\vec{\theta})}{Z(\text{Datos}, \text{Modelo})}$$

$$\textit{Posterior} = \frac{\textit{Verosimilitud} * \textit{Prior}}{\textit{Evidencia}}$$



TEOREMA DE BAYES PARA INFERENCIA DE PARAMETROS

VEROSIMILITUD

Es necesario definirla en función de los datos, Suele definirse como gaussiana pero realmente podría tener otra distribución, p.e. Poisson es mejor para experimentos de conteo...

PRIORS



Conocimiento previo sobre los parámetros de nuestro modelo antes de los nuevos datos. A medida que la verosimilitud es más restrictiva, los priors dejan de ser importantes, aun así es mejor intentar trabajar con priors no informativos.

POSTERIOR


Cuando hay pocos parámetros hacer una grilla es factible. Sin embargo, en la mayoría de las ocasiones es necesario implementar métodos numéricos avanzados.

$$P(\vec{\theta}|\mathcal{D}) = \frac{P(\mathcal{D}|\vec{\theta})P(\vec{\theta})}{P(\mathcal{D})}$$


$$P(\mathcal{D}) = \int P(\mathcal{D}|\vec{\theta})P(\vec{\theta}) d\vec{\theta}$$



$$P(\vec{\theta}|\mathcal{D}) = \frac{P(\mathcal{D}|\vec{\theta})P(\vec{\theta})}{P(\mathcal{D})}$$



$$P(\mathcal{D}) = \int P(\mathcal{D}|\vec{\theta})P(\vec{\theta}) d\vec{\theta}$$



PROBLEMA 1

Se requiere de muchos puntos, el numero de puntos escala exponencialmente con el numero de parametros.

$$20 \times 20 = 400$$


$$20^3 = 8000$$

$$20^{64} > 10^{82}$$



The curse of dimensionality!

PROBLEMA 2

El metodo no es muy util con distribuciones no simetricas




$$P(\vec{\theta}|\mathcal{D}) = \frac{P(\mathcal{D}|\vec{\theta})P(\vec{\theta})}{P(\mathcal{D})}$$



MARKOV CHAIN MONTE CARLO

Vamos a considerar una cadena de Markov con distribución estacionaria única y restrictiva $P(x)$



IDEA GENERAL

- Construir una cadena de Markov cuya distribución $P(D|0)$ sea estacionaria, única y restrictiva.
- Usar esta cadena de Markov para generar muestras $01, 02, 03, \dots$ a partir de $P(D|0)$

ALGORITMOS

- Metropolis-Hastings
- Gibbs
- Langevin
- Hamiltonian Monte Carlo
- Slice sampling
- Multiple-try Metropolis
- Reversible Jump

- **Markov chain:** MCMC generates a sequence of samples where each new sample is chosen based on the location of the previous one, a concept known as the Markov property.
- **Guided exploration:** Instead of random sampling, the algorithm uses the probability of the current location to propose a new one. It tends to explore regions of high probability more frequently, though it also includes a chance of accepting "worse" locations to avoid getting stuck in a local maximum.
- **Accept or reject:** An algorithm decides whether to accept or reject the new sample. If the new location is better, it's more likely to be accepted. Even if it's worse, there's still a chance it will be accepted to ensure the chain explores the entire distribution.
- **Burn-in and equilibrium:** The initial samples are discarded as the chain "warms up" and finds its way to the high-probability regions of the distribution. Once it reaches equilibrium, the samples are considered representative of the target distribution.
- **Approximating the distribution:** By repeating this process many times, the chain of accepted samples will eventually represent the target probability distribution, allowing for analysis of the problem.


METROPOLIS-HASTINGS

El algoritmo de Metropolis-Hastings para muestrear a partir de $P(x)$.

1. $\vec{\theta}_{start} = \vec{\theta}_i$
2. Propose $\theta_{i,trial}$ from $\mathcal{N}(\theta_i, \sigma_i)$ (Other algorithms have different proposal distributions)
3. Compute acceptance probability $p_{acc} = \min(1, P(\vec{\theta}_{trial})/P(\vec{\theta}_i))$
 1. Es posible usar el logaritmo del posterior en lugar del posterior directamente.
i.e. $p_{acc} = \exp(\min(0, \ln(P(\theta_{trial})) - \ln(P(\theta_i))))$
4. Accept proposal with probability $p_{acc} > (u \in U(0,1))$
 - If accept: $\vec{\theta}_{i+1} = \vec{\theta}_{trial}$
 - Else: $\vec{\theta}_{i+1} = \vec{\theta}_i$
 - Save and go to step 1

After N iterations asses convergence:

- Qualitative: Look at parameter series and 2D distributions
- Quantitative: e.g. Gelman-Rubin test, autocorrelation...



"Equation of State Calculations by Fast Computing Machines"

Nicholas Metropolis, Arianna W. Rosenbluth, and Marshall N. Rosenbluth

Los Alamos Scientific Laboratory, Los Alamos, New Mexico

and

Augusta H. Teller* and Edward Teller[†]

Department of Physics, University of Chicago, Chicago, Illinois

Monte Carlo sampling methods using Markov chains and their applications

By W. K. HASTINGS
University of Toronto

SUMMARY

A generalization of the sampling method introduced by Metropolis *et al.* (1953) is presented along with an exposition of the relevant theory, techniques of application and methods and difficulties of assessing the error in Monte Carlo estimates. Examples of the methods, including the generation of random orthogonal matrices and potential applications of the methods to numerical problems arising in statistics, are discussed.


METROPOLIS-HASTINGS

$$P(\vec{\theta} \mid \text{Datos, Modelo}) \propto \mathcal{L}(\text{Datos} \mid \vec{\theta}, \text{Modelo}) \pi(\vec{\theta})$$

$$P(D|\theta) = \prod_i \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[-\frac{(y_i - y_{\text{modelo}}(x_i; \theta))^2}{2\sigma^2} \right]$$

$$\chi^2(\theta) = \sum_i \frac{[y_i - y_{\text{modelo}}(x_i, \theta)]^2}{\sigma_i^2}$$

$$\log \mathcal{L}(\theta) = -\frac{1}{2} \sum_i \frac{(y_i - y_{\text{modelo}}(x_i, \theta))^2}{\sigma_i^2} - \frac{1}{2} \sum_i \log(2\pi\sigma_i^2) \quad \longrightarrow$$



GRACIAS

